
29º ENAPOL, USP, 2026

Corpus Computacional e Gramática Executável do Tupi Antigo

quando cada linha do corpus se torna um teste da análise

Kian Arad Sheik

USP / PPG Linguística

O QUE O PROJETO FAZ

Transformo análise linguística em uma gramática executável.

CORPUS

cada ocorrência recebe fonte, leitura, alvo normalizado, segmentação, glosas e interpretação controladas.

GRAMÁTICA

morfemas, alomorfes, relações sintáticas e valores semânticos são escritos como objetos formais reutilizáveis.

TESTE

a estrutura roda, gera uma forma de superfície e confronta a hipótese com a análise linguística daquela linha.

O caso concreto é Tupi Antigo; a contribuição maior é um método reutilizável para línguas de corpus.

DA GRAMÁTICA COMO TEXTO À GRAMÁTICA COMO TESTE

A metalinguagem muda; a hipótese gramatical continua.




TODO
Anchieta, 1595
pagina sobre o mesmo topico

GRAMÁTICA HISTÓRICA
ANCHIETA, 1595



TODO
Gerardi / moderna
pagina sobre o mesmo topico

DESCRIÇÃO MODERNA
GERARDI / DESCRIÇÃO ATUAL



TODO
pydicat executable grammar
substituir por screenshot real

morfema + relacao + alvo
spell_out() -> forma gerada
compare() -> teste

CAMADA EXECUTÁVEL
MESMA ANÁLISE, NOVO MODO DE TESTE

A proposta não substitui a gramática escrita; acrescenta uma camada formal que pode ser executada, versionada e corrigida.

DIFICULDADE PRINCIPAL

Não é automação. É trabalho gramatical em outra metalinguagem.

CONTINUIDADE

é o mesmo tipo de descrição gramatical feito em gramáticas históricas e modernas: analisar, categorizar e justificar.

METALINGUAGEM

em vez de prosa gramatical europeia, uso Python e uma pequena camada pydicate para tornar a hipótese executável.

GARGALO

nesta etapa, a mesma pessoa precisa analisar Tupi Antigo, decidir a representação e programar a estrutura.

POR QUE É DIFÍCIL?

O bootstrapping revela necessidades do método que só aparecem quando a gramática tenta gerar o corpus.

EXEMPLO

Araújo, Catecismo, Padre Nosso

TODO

Araújo ou Bettendorff

recorte da linha curta



ARAÚJO, 1686, LIVRO I, PADRE NOSSO, P. 2, LINHAS 1-2

ALVO NORMALIZADO ATUAL

oré rembi'u 'ara îabi'õndûara
eîme'eng kori orébe

"Dá-nos hoje o nosso alimento de cada dia."

POSSE NOMINAL

NOMINALIZAÇÃO

EXPRESSIONAÇÃO TEMPORAL

IMPERATIVO

DATIVO: ORÉBE

A mesma análise, escrita como estrutura formal.

MORFEMAS DE BASE

ORÉ	pronome	'U	raiz
1ppe		verbal "comer"	
EMI		'ARA	nome
nominalizador		"dia"	
paciente			
ÎABI'Ô		NDÛARA	
posposição "cada"		nominalizador	
		adverbial	
ME'ENG	verbo	ENDÉ	pronome
"dar"		2ps	
KORI	advérbio	SUPÉ	
"hoje"		posposição dativa	

ESTRUTURA FORMAL

```
(( (emi * (u * oré))
  @ (nduara * (ara * iabiô)))
 * (meeng * +endé).imp())
+ kori
+ (supé * oré).var(1)
```

SPELL-OUT

oré rembi'u 'ara
îabi'ôndûara
eîme'eng kori
orébe

Registro local:
ARAUJO_CATECISMO_1686:0007

MORFEMAS

listar formas de base, não apenas a forma de superfície produzida.

SINTAXE

compor posse, modificação temporal, imperativo e dativo.

VERIFICAÇÃO


comparar forma gerada, estrutura e rótulos com a análise aprovada.

ESTRUTURA

A linha do corpus vira uma árvore consultável.

oré rembi'u 'ara íabi'õndũara eime'eng kori orébe

gerado de oldtupicorpus/historic/araujo_catecismo_1686.tu.py · índice 6




árvore gerada do objeto pydiccate; rótulos e relações vêm dos atributos estruturais usados pela gramática

O GANHO DESCRITIVO

A forma gerada não é só uma string. A análise guarda morfemas, relações, rótulos e decomposições.

- **REMBI'U** como estrutura possuída;
- tempo e frequência como modificador;
- imperativo como forma verbal derivada;
- **SUPÉ * ORÉ** gerando a forma superficial **ORÉBE**.

Cada linha validada aumenta a obrigação das regras anteriores.



Cada linha validada aumenta a obrigação das regras anteriores.

ESTADO PERSISTENTE

GRAMÁTICA + LÉXICO

morfemas, alomorfes, valores gramaticais, relações sintáticas e etiquetas semânticas acumulam no mesmo sistema.

1

linha n

fonte, leitura, alvo e glosa



2

morfemas

reusar ou definir objetos



3

estrutura

sintaxe e relações abstratas

4

spell-out

EVAL gera forma de superfície



5

conferência

forma, estrutura e rótulos

Cada linha validada aumenta a obrigação das regras anteriores.

ESTADO PERSISTENTE

GRAMÁTICA + LÉXICO

morfemas, alomorfes, valores gramaticais, relações sintáticas e etiquetas semânticas acumulam no mesmo sistema.

1

linha n

fonte, leitura, alvo e glosa



2

morfemas

reusar ou definir objetos



3

estrutura

sintaxe e relações abstratas

4

spell-out

EVAL gera forma de superfície



5

conferência

forma, estrutura e rótulos

6

ground truth

linha aprovada vira teste futuro

Cada linha validada aumenta a obrigação das regras anteriores.

ESTADO PERSISTENTE

GRAMÁTICA + LÉXICO

morfemas, alomorfes, valores gramaticais, relações sintáticas e etiquetas semânticas acumulam no mesmo sistema.

1

linha n

fonte, leitura, alvo e glosa



2

morfemas

reusar ou definir objetos



3

estrutura

sintaxe e relações abstratas

4

spell-out

Eval gera forma de superfície



5

conferência

forma, estrutura e rótulos

6

ground truth

linha aprovada vira teste futuro

7

regressão

regenerar tudo de 1...N



8

diff

mostrar onde e o que mudou

Cada linha validada aumenta a obrigação das regras anteriores.



Cada linha validada aumenta a obrigação das regras anteriores.



Uma correção local pode ser testada contra todo o corpus já validado.

O QUE ISSO TORNA POSSÍVEL

Um corpus integral seria uma infraestrutura de pesquisa.

TRAJETÓRIA

O primeiro passo começou no mestrado. Com gramática suficiente implementada, o projeto foi aprovado para Doutorado Direto para avançar no corpus conhecido de Tupi Antigo.

CONSULTA

morfemas, alomorfes, ambientes sintáticos, estruturas argumentais, rótulos semânticos e variação ortográfica ficam consultáveis.

REVISÃO

se uma regra estiver errada ou mal rotulada, ela é corrigida em um ponto e testada contra tudo que já foi implementado.

EXEMPLO JÁ PRODUZIDO

O trabalho sobre switch reference apresentado na Amazônicas X já usou corpus parcialmente anotado para localizar e quantificar padrões gramaticais.

Tupi Antigo é finito o bastante para implementação séria e amplo o bastante para análise linguística substantiva.

LINKS

Saídas públicas da mesma infraestrutura formal



Apresentação

kiansheik.github.io/public-presentations
slides e PDF exportável




Corpus / gramática

github.com/kiansheik/oldtupicorpus
implementação composicional e testes



Dicionário

kiansheik.io/nhe-eng
consulta lexical e formas geradas



Neologismos

neo.academiaturpi.com
formas novas seguindo a gramática

As aplicações são saídas. O objeto científico é a gramática executável.

A gramática deixa de ser apenas uma interpretação do corpus e passa a ser uma hipótese que o corpus pode testar.