

ENAPOL 2026

Corpus Computacional e Gramática Executável do Tupi Antigo

quando cada linha do corpus se torna um teste da análise

Kian Arad Sheik

USP / PPG Linguística

O PROBLEMA

Tupi Antigo tem fontes.

O conhecimento linguístico está distribuído entre gramáticas históricas, catecismos, textos do corpus, dicionários, descrições modernas e convenções editoriais.

Esses dados foram organizados para leitura humana. O desafio é torná-los comparáveis, testáveis e revisáveis de modo sistemático.

ANCHIETA

fonte histórica

SUBSTITUIR POR PNGUJPG

ANCHIETA, 1595

[REFERÊNCIA /
PÁGINA A INSERIR]

CORPUS

Araújo ou Bettendorff

SUBSTITUIR POR PNGUJPG

**ARAÚJO OU
BETTENDORFF**

[FONTE / PÁGINA A
INSERIR]

MODERNA

descrição / dicionário

SUBSTITUIR POR PNGUJPG

**DESCRIÇÃO OU
DICIONÁRIO
MODERNO**

[REFERÊNCIA A
INSERIR]

UMA LINHA CONCRETA

Uma linha do corpus pode testar uma gramática

1. FORMA ATESTADA

LINHA ATESTADA

A mesma linha deve alimentar todos os painéis

[FONTE / PÁGINA A INSERIR]

2. ANÁLISE LINGÜÍSTICA
[INSERIR AQUI
O FENÔMENO
ESCOLHIDO, A
SEGMENTAÇÃO
E A LEITURA
GRAMATICAL
DA MESMA
LINHA]

3. EXPRESSÃO FORMAL

T000: expressao formal

```
clause(  
  subject=...  
  predicate=...  
  features={...}  
)
```

PYDICATE / REPRESENTAÇÃO
FORMAL

4. SAÍDA GERADA

SAIDA GERADA

Forma/anotacao da mesma linha

forma-superficial
morfema morfema morfema
GLOSSA GLOSSA GLOSSA

FORMA E ANOTAÇÃO GERADAS

A forma atestada confronta a
análise formal.

REGRA?

ANÁLISE?

LÉXICO?

VARIAÇÃO ORTOGRÁFICA?

TRADIÇÃO TEXTUAL?

CÓDIGO COMO METALINGUAGEM LINGÜÍSTICA

Linguistas já usam metalinguagens formais.

PROSA

regra formulada
em linguagem
natural

GLOSA

segmentação e
valores
gramaticais

REPRESENTAÇÃO FORMAL

análise escrita
como estrutura
explícita

SAÍDA VERIFICÁVEL

forma
comparável ao
corpus


Uma linguagem de programação também pode funcionar como metalinguagem formal para descrição linguística.

METALINGUAGENS EM COMPARAÇÃO

Da prosa gramatical à formalização executável

ANCHIETA: MESMO FENOMENO


Capturar passagem específica da gramática



ANCHIETA, 1595
[PASSAGEM / PÁGINA A INSERIR]

DESCRICAO MODERNA

Mesmo fenomeno da passagem de Anchieta



DESCRIÇÃO MODERNA
[AUTOR, OBRA, PÁGINA A INSERIR]

TODO: expressao formal

```
clause(  
  subject=...  
  predicate=...  
  features={...}  
)
```

GRAMÁTICA EXECUTÁVEL
MESMO FENÔMENO, CAMADA FORMAL

A necessidade de uma metalinguagem permanece; as metalinguagens disponíveis mudam.

Cada linha acrescenta uma nova obrigação à gramática.

ESTADO PERSISTENTE

GRAMÁTICA + LÉXICO

morfemas, alomorfes, valores gramaticais, relações sintáticas e etiquetas semânticas acumulam no mesmo sistema.

1

linha n

forma e análise esperadas



2

morfemas

reusar ou definir objetos



3

estrutura abstrata

objetos + relações + sintaxe

Cada linha acrescenta uma nova obrigação à gramática.

ESTADO PERSISTENTE

GRAMÁTICA + LÉXICO

morfemas, alomorfes, valores gramaticais, relações sintáticas e etiquetas semânticas acumulam no mesmo sistema.

1

linha n

forma e análise esperadas



2

morfemas

reusar ou definir objetos



3

estrutura abstrata

objetos + relações + sintaxe

4

spell-out

EVAL → forma de superfície



5

conferência linguística

forma, morfemas, estrutura, rótulos

Cada linha acrescenta uma nova obrigação à gramática.

ESTADO PERSISTENTE

GRAMÁTICA + LÉXICO

morfemas, alomorfes, valores gramaticais, relações sintáticas e etiquetas semânticas acumulam no mesmo sistema.

1

linha n

forma e análise esperadas



2

morfemas

reusar ou definir objetos



3

estrutura abstrata

objetos + relações + sintaxe

4

spell-out

EVAL → forma de superfície



5

conferência linguística

forma, morfemas, estrutura, rótulos

6

linha validada

novo teste para versões futuras

Cada linha acrescenta uma nova obrigação à gramática.

ESTADO PERSISTENTE

GRAMÁTICA + LÉXICO

morfemas, alomorfes, valores gramaticais, relações sintáticas e etiquetas semânticas acumulam no mesmo sistema.

1

linha n

forma e análise esperadas



2

morfemas

reusar ou definir objetos



3

estrutura abstrata

objetos + relações + sintaxe

4

spell-out

EVAL → forma de superfície



5

conferência linguística

forma, morfemas, estrutura, rótulos

6

linha validada

novo teste para versões futuras

7

regressão completa

1...N → regenerar → diff



8

Regressões?

o sistema mostra onde e o que mudou

Cada linha acrescenta uma nova obrigação à gramática.

ESTADO PERSISTENTE

GRAMÁTICA + LÉXICO

morfemas, alomorfes, valores gramaticais, relações sintáticas e etiquetas semânticas acumulam no mesmo sistema.

1

linha n

forma e análise esperadas



2

morfemas

reusar ou definir objetos



3

estrutura abstrata

objetos + relações + sintaxe

4

spell-out

EVAL → forma de superfície



5

conferência linguística

forma, morfemas, estrutura, rótulos

6

linha validada

novo teste para versões futuras

7

regressão completa

1...N → regenerar → diff



8

Regressões?

o sistema mostra onde e o que mudou

SIM → CORRIGIR REGRA / LÉXICO / ANÁLISE

NÃO → PRÓXIMA LINHA: $n \leftarrow n + 1$

Cada linha acrescenta uma nova obrigação à gramática.



Uma correção local pode ser testada imediatamente contra todo o corpus validado.

As aplicações são saídas. O objeto científico é a gramática.

GRAMÁTICA COMPUTACIONAL



PROVA DE CONCEITO



DOUTORADO DIRETO



CORPUS INTEGRAL + METODOLOGIA

Primeira fase

O projeto começou no mestrado com a construção da gramática computacional. Ela amadureceu o bastante para sustentar flexão, dicionários, ensino, ortografia, neologismos e infraestrutura de anotação.


DICIONARIO / CONJUGACAO

Substituir por screenshot real



SAIDA PUBLICA

TupiTrail, neologismos ou material comunitario



Agora, no doutorado

Com a maturação da gramática computacional, o projeto foi aprovado para Doutorado Direto.

O objetivo agora é implementar sistematicamente o corpus conhecido do Tupi Antigo dentro dessa gramática e, ao fazê-lo, aperfeiçoar simultaneamente a gramática e o método.

MUDANÇA DE ESCALA

de ferramentas geradas pela gramática para uma gramática testada linha por linha pelo corpus.

Um corpus parcial já permitiu inferência gramatical.

AMAZÔNICAS X

Switch reference em Tupi Antigo

Establishing Switch Reference in Old Tupi:
Evidence for Conjunctive as a DS Marker

62

EXEMPLOS ANOTADOS

96,77%

DS

3,23%

SS

Fonte verificada: versão local do artigo e
`annotated\_citations.json`. O resumo público do ResearchGate
registra uma versão anterior com 53 exemplos.

O que isso demonstra?

Mesmo uma anotação parcial já tornou mais rápido
localizar, comparar e quantificar exemplos relevantes.

CORPUS PARCIAL → EXEMPLOS CONSULTÁVEIS → PADRÃO DETECTÁVEL

O corpus integral amplia esse ganho para morfemas,
alomorfia, ambientes sintáticos, estrutura argumental,
variação ortográfica, mudança semântica e
contraexemplos.

Quando o corpus conhecido inteiro se torna consultável

Não é só velocidade

É colocar análises diferentes dentro da mesma representação explícita, versionada e regenerável.

O que se torna perguntável

- distribuição de morfemas e alomorfes;
- ambientes sintáticos e estrutura argumental;
- rótulos semânticos e mudança de sentido;
- variação ortográfica e tradição textual;
- análises concorrentes, exceções e contraexemplos.

Escopo metodológico

Tupi Antigo é o caso concreto: finito o bastante para ser implementável, amplo o bastante para análise séria, documentado o bastante para não depender de especulação pura.

A proposta pode ser reutilizada em outras línguas de corpus com tradições suficientemente delimitadas e analisáveis.

Tupi Antigo é o primeiro caso de implementação; a metodologia não precisa terminar nele.

EXPLORE O ECOSSISTEMA

Saídas públicas da mesma infraestrutura formal



Dicionário

kiansheik.io/nhe-eng
consulta lexical e formas geradas



Gramática / corpus

github.com/kiansheik/oldtupicorpus
implementação composicional do corpus



Neologismos

neo.academiatuspi.com
aplicação pública apoiada pelo trabalho
formal

Tupi Antigo é o caso concreto. A proposta metodológica é maior que uma língua.

A gramática deixa de ser apenas uma interpretação do corpus e passa a ser uma hipótese que o corpus pode testar.