
29º ENAPOL, USP, 2026

Corpus Computacional e Gramática Executável do Tupi Antigo

quando cada linha do corpus se torna um teste da análise

Kian Arad Sheik

USP / PPG Linguística

Orientador: Prof. Dr. Thomas Daniel Finbow



O QUE EU FAÇO

Da fonte histórica a uma hipótese gramatical que pode falhar.

1 • CORPUS

localizo a ocorrência,
preservo a fonte e estabeleço
leitura, normalização, glosas
e interpretação.

2 • DESCRIÇÃO

morfemas, alomorfes e
relações gramaticais viram
objetos formais reutilizáveis.

3 • TESTE

a estrutura é executada e
confrontada com a linha que
pretende explicar.

O computador não substitui a análise linguística. Ele obriga a análise a ser explícita.

A proposta não é substituir a gramática escrita.

descrição escrita

explica categorias, generalizações, exceções e argumentos em linguagem humana.

INDISPENSÁVEL PARA INTERPRETAR E JUSTIFICAR

camada executável

obriga essas decisões a terem forma suficiente para gerar, anotar e ser testadas.

UMA HIPÓTESE FORMAL QUE O CORPUS PODE CONTRARIAR

efeito metodológico

cada decisão nova precisa continuar compatível com as linhas já validadas.

DESCRIÇÃO CUMULATIVA, NÃO EXEMPLOS ISOLADOS

A proposta não é substituir a gramática escrita. É acrescentar uma camada formal executável.

UM MESMO PROBLEMA EM TRÊS METALINGUAGENS

çupê / supe / supé: da descrição à execução

ANCHIETA, 1595

ARTE DE GRAMMATICA DA LINGOA MAIS USADA NA COSTA DO BRASIL

"ÇUPÊ": DATIVO, PARA, POR

7.8.1 Locative-Dative cases

The locative is expressed by *pe*, which also expresses motion towards the referent (allative), and also marks the recipient or beneficiary (dative). Locative examples are given in (385). All variants are here glossed as LOC.

- (385) a. *jepope*
je=po-**pe**
1SG=hand-LOC
'In my hand(s).' (AT, 48)
- b. *Nejurarawaj tápe*
ne=Ø-jurarawaj taβ-**pe**
2SG=R1-lie village-LOC
'You lie in the village.' (DC, II, 84)
- c. *Ma?eramaripe ase tipe oeni*
ma?e-rama-ri=pe ase Ø-ti-**pe** o-eni-Ø
thing-FUT-PRCL=Q our R1-nose-LOC CORF-saliva-REF

FERRAZ GERARDI, 2023

A ROLE AND REFERENCE GRAMMAR DESCRIPTION OF TUPINAMBÁ

"SUPE": DATIVO / POSPOSIÇÃO NA ANÁLISE MODERNA

```
class Dative(Postposition):
```

```
    def __init__(self,
                    definition="to, for, in favor
of"):
```

```
        super().__init__(
            "supé",
            definition=definition,
```

```
            *args=ll
```

PYDICATE

supé COMO OBJETO GRAMATICAL EXECUTÁVEL

A metalinguagem muda; o projeto depende das descrições anteriores para tornar a hipótese executável.

O PROBLEMA CONCRETO

Uma frase histórica não é apenas uma sequência de palavras.

SUPERFÍCIE

a fonte registra formas já compostas, com ortografia histórica e fronteiras que nem sempre coincidem com a análise.

ESTRUTURA

a descrição precisa recuperar relações morfológicas e sintáticas que não estão separadas visualmente.


RESPONSABILIDADE

se eu proponho uma decomposição, a gramática precisa conseguir usá-la sem perder as formas já explicadas.

QUESTÃO

Como representar a forma que aparece na fonte sem confundir superfície gráfica com estrutura gramatical?

orébe na superfície; oré + supé na análise.



ARAÚJO, 1686, LIVRO I, PADRE NOSSO

ALVO NORMALIZADO

oré rembi'u 'ara îabi'õndûara
eîme'eng kori orébe

“Dá-nos hoje o nosso alimento de cada dia.”

FORMA DE SUPERFÍCIE **ORÉBE**

FUNÇÃO **DATIVO: “A NÓS / PARA NÓS”**

ANÁLISE MAIS
PROFUNDA **ORÉ + SUPÉ**

A segmentação analítica não precisa coincidir com espaços na fonte.

A MESMA LINHA COMO OBJETO FORMAL

A análise precisa produzir a forma e conservar a estrutura.

NO CORPUS EXECUTÁVEL

```
orébe = (oré * supé).var(1)
```


```
***
```

```
((emi * (u * oré))  
  @ (nduara * (ara * iabiõ)))  
  * (meeng * +endé).imp())  
+ kori  
+ orébe
```

O objeto guarda a análise; o
spell-out devolve **ORÉBE**.

oré rembi'u 'ara iabi'õndũara eime'eng kori orébe

gerado de oldtupicorpus/historic/araujo_catecismo_1686.tu.py · índice 6



Árvore gerada do objeto pydiccate; rótulos e relações vêm dos atributos estruturais usados pela gramática

A forma correta não basta: a estrutura produzida também faz parte da hipótese.

DO EXEMPLO AO MÉTODO

Cada linha validada vira um teste.

ESTADO PERSISTENTE

GRAMÁTICA + LÉXICO

cada análise aprovada
aumenta o conjunto de
decisões que uma mudança
futura precisa respeitar.

1

fonte histórica

linha e contexto documental



2

estrutura formal

morfemas e relações explícitas



3

forma gerada / anotada

resultado da hipótese

DO EXEMPLO AO MÉTODO

Cada linha validada vira um teste.

ESTADO PERSISTENTE

GRAMÁTICA + LÉXICO

cada análise aprovada
aumenta o conjunto de
decisões que uma mudança
futura precisa respeitar.

1

fonte histórica

linha e contexto documental



2

estrutura formal

morfemas e relações explícitas



3

forma gerada / anotada

resultado da hipótese

4

ground truth

comparar com a linha validada



5

revisão

regra, léxico ou análise

DO EXEMPLO AO MÉTODO

Cada linha validada vira um teste.

ESTADO PERSISTENTE

GRAMÁTICA + LÉXICO

cada análise aprovada
aumenta o conjunto de
decisões que uma mudança
futura precisa respeitar.

1

fonte histórica

linha e contexto documental



2

estrutura formal

morfemas e relações explícitas



3

forma gerada / anotada

resultado da hipótese

4

ground truth

comparar com a linha validada



5

revisão

regra, léxico ou análise



6

regressão

rodar novamente as linhas anteriores

7

próxima linha

só depois de preservar o que já funcionava

Cada linha validada vira um teste.

ESTADO PERSISTENTE

GRAMÁTICA + LÉXICO

cada análise aprovada
aumenta o conjunto de
decisões que uma mudança
futura precisa respeitar.

1

fonte histórica

linha e contexto documental



2

estrutura formal

morfemas e relações explícitas



3

forma gerada / anotada

resultado da hipótese

4

ground truth

comparar com a linha validada



5

revisão

regra, léxico ou análise

6

regressão

rodar novamente as linhas anteriores



7


próxima linha

só depois de preservar o que já funcionava

SÍNTESE

Uma análise aprovada deixa de ser exemplo isolado e passa a ser compromisso da gramática inteira.

Cada linha validada vira um teste.



O corpus obriga a gramática a prestar contas.

O QUE ISSO TORNA POSSÍVEL

As ferramentas são saídas. O objeto científico é a gramática executável.

CONSULTA LINGUÍSTICA

buscar morfemas, alomorfes, ambientes sintáticos e estruturas em um corpus analisado de modo consistente.

REVISÃO EXPLÍCITA

mudar uma generalização e ver exatamente quais análises anteriores deixam de funcionar.

NOVAS PERGUNTAS

quantificar distribuições e localizar padrões sem separar a busca dos pressupostos gramaticais que a tornam possível.

PRODUTOS DERIVADOS

dicionários, geração e outras interfaces podem reutilizar a mesma descrição sem se tornarem o centro do projeto.

A gramática deixa de ser apenas uma interpretação do corpus e passa a ser uma hipótese que o corpus pode testar.

UMA SAÍDA PÚBLICA DA MESMA INFRAESTRUTURA

O código da gramática já alimenta um dicionário colaborativo.



neo.academiatuspi.com

dicionário colaborativo de neologismos em
Tupi Antigo

PROJETO INICIADO EM MARÇO DE 2026

Em pouco mais de cinco meses: mais de 1000 verbetes, com áudio, citações e revisão comunitária

Aberto e financiado coletivamente. A comunidade propõe verbetes e exemplos, vota, revisa fontes e participa por meio de perfis e karma.

1096

verbetes

189

exemplos

24

usuários

Não é o objeto da pesquisa. É um lugar em que a gramática executável já está sendo usada por uma comunidade.

A gramática executável não termina no teste: ela também pode sustentar ferramentas abertas.