

ENAPOL 2026

# Corpus Computacional e Gramática Executável do Tupi Antigo

quando cada linha do corpus se torna um teste da análise

---

**Kian Arad Sheik**

USP / PPG Linguística

## O PROBLEMA

# Tupi Antigo tem fontes.

O conhecimento linguístico está distribuído entre gramáticas históricas, catecismos, textos do corpus, dicionários, descrições modernas e convenções editoriais.

Esses dados foram organizados para leitura humana. O desafio é torná-los comparáveis, testáveis e revisáveis de modo sistemático.

### ANCHIETA

fonte histórica

SUBSTITUIR POR PNGUJPG

**ANCHIETA, 1595**

[REFERÊNCIA /  
PÁGINA A INSERIR]

### CORPUS

Araújo ou Bettendorff

SUBSTITUIR POR PNGUJPG

**ARAÚJO OU  
BETTENDORFF**

[FONTE / PÁGINA A  
INSERIR]

### MODERNA

descrição / dicionário

SUBSTITUIR POR PNGUJPG

**DESCRIÇÃO OU  
DICIONÁRIO  
MODERNO**

[REFERÊNCIA A  
INSERIR]

## UMA LINHA CONCRETA

# Uma linha do corpus pode testar uma gramática

### 1. FORMA ATESTADA

**LINHA ATESTADA**

A mesma linha deve alimentar todos os painéis

[FONTE / PÁGINA A INSERIR]

**2. ANÁLISE LINGUÍSTICA**  
[INSERIR AQUI  
O FENÔMENO  
ESCOLHIDO, A  
SEGMENTAÇÃO  
E A LEITURA  
GRAMATICAL  
DA MESMA  
LINHA]

### 3. EXPRESSÃO FORMAL

```
T000: expressao formal

clause(
  subject=...
  predicate=...
  features=...)
}
```

**PYDICATE / REPRESENTAÇÃO  
FORMAL**

### 4. SAÍDA GERADA

**SAIDA GERADA**

Forma/anotacao da mesma linha

forma-superficial  
morfema morfema morfema  
GLOSSA GLOSSA GLOSSA

**FORMA E ANOTAÇÃO GERADAS**

**A forma atestada confronta a  
análise formal.**

REGRA?

ANÁLISE?

LÉXICO?

VARIAÇÃO ORTOGRÁFICA?

TRADIÇÃO TEXTUAL?

CÓDIGO COMO METALINGUAGEM LINGÜÍSTICA

# Linguistas já usam metalinguagens formais.

## PROSA

regra formulada  
em linguagem  
natural

## GLOSA

segmentação e  
valores  
gramaticais

## REPRESENTAÇÃO FORMAL

análise escrita  
como estrutura  
explícita

## SAÍDA VERIFICÁVEL

forma  
comparável ao  
corpus


Uma linguagem de programação também pode funcionar como metalinguagem formal para descrição linguística.

## METALINGUAGENS EM COMPARAÇÃO

# Da prosa gramatical à formalização executável

### ANCHIETA: MESMO FENOMENO


Capturar passagem específica da gramática



**ANCHIETA, 1595**  
[PASSAGEM / PÁGINA A INSERIR]

### DESCRICAO MODERNA

Mesmo fenomeno da passagem de Anchieta



**DESCRIÇÃO MODERNA**  
[AUTOR, OBRA, PÁGINA A INSERIR]

TODO: expressao formal

```
clause(  
  subject=...  
  predicate=...  
  features={...}  
)
```

**GRAMÁTICA EXECUTÁVEL**  
MESMO FENÔMENO, CAMADA FORMAL

**A necessidade de uma metalinguagem permanece; as metalinguagens disponíveis mudam.**

# Cada linha acrescenta uma nova obrigação à gramática.



Uma correção local pode ser testada imediatamente contra todo o corpus validado.

# As aplicações são saídas. O objeto científico é a gramática.

GRAMÁTICA COMPUTACIONAL



PROVA DE CONCEITO



DOUTORADO DIRETO



CORPUS INTEGRAL + METODOLOGIA

## Primeira fase

O projeto começou no mestrado com a construção da gramática computacional. Ela amadureceu o bastante para sustentar flexão, dicionários, ensino, ortografia, neologismos e infraestrutura de anotação.


### DICIONARIO / CONJUGACAO

Substituir por screenshot real



### SAIDA PUBLICA

TupiTrail, neologismos ou material comunitario



## Agora, no doutorado

Com a maturação da gramática computacional, o projeto foi aprovado para Doutorado Direto.

O objetivo agora é implementar sistematicamente o corpus conhecido do Tupi Antigo dentro dessa gramática e, ao fazê-lo, aperfeiçoar simultaneamente a gramática e o método.

### MUDANÇA DE ESCALA

de ferramentas geradas pela gramática para uma gramática testada linha por linha pelo corpus.

# Um corpus parcial já permitiu inferência gramatical.

AMAZÔNICAS X

## Switch reference em Tupi Antigo

Establishing Switch Reference in Old Tupi:  
Evidence for Conjunctive as a DS Marker

62

EXEMPLOS ANOTADOS

96,77%

DS

3,23%

SS

Fonte verificada: versão local do artigo e  
`annotated\_citations.json`. O resumo público do ResearchGate  
registra uma versão anterior com 53 exemplos.

## O que isso demonstra?

Mesmo uma anotação parcial já tornou mais rápido  
localizar, comparar e quantificar exemplos relevantes.

CORPUS PARCIAL → EXEMPLOS CONSULTÁVEIS → PADRÃO DETECTÁVEL

O corpus integral amplia esse ganho para morfemas,  
alomorfia, ambientes sintáticos, estrutura argumental,  
variação ortográfica, mudança semântica e  
contraexemplos.

# Quando o corpus conhecido inteiro se torna consultável

## Não é só velocidade

É colocar análises diferentes dentro da mesma representação explícita, versionada e regenerável.

## O que se torna perguntável

- distribuição de morfemas e alomorfes;
- ambientes sintáticos e estrutura argumental;
- rótulos semânticos e mudança de sentido;
- variação ortográfica e tradição textual;
- análises concorrentes, exceções e contraexemplos.

## Escopo metodológico

Tupi Antigo é o caso concreto: finito o bastante para ser implementável, amplo o bastante para análise séria, documentado o bastante para não depender de especulação pura.

A proposta pode ser reutilizada em outras línguas de corpus com tradições suficientemente delimitadas e analisáveis.

**Tupi Antigo é o primeiro caso de implementação; a metodologia não precisa terminar nele.**

EXPLORE O ECOSSISTEMA

## Saídas públicas da mesma infraestrutura formal



### Dicionário

kiansheik.io/nhe-eng  
consulta lexical e formas geradas



### Gramática / corpus

github.com/kiansheik/oldtupicorpus  
implementação composicional do corpus



### Neologismos

neo.academiatuspi.com  
aplicação pública apoiada pelo trabalho  
formal

Tupi Antigo é o caso concreto. A proposta metodológica é maior que uma língua.

A gramática deixa de ser apenas uma interpretação do corpus e passa a ser uma hipótese que o corpus pode testar.