

ENAPOL 2026

Corpus Computacional e Gramática Executável do Tupi Antigo

quando cada linha do corpus se torna um teste da análise

Kian Arad Sheik

USP / PPG Linguística

O PROBLEMA

Tupi Antigo tem fontes.

O conhecimento linguístico está distribuído entre gramáticas históricas, catecismos, textos do corpus, dicionários, descrições modernas e convenções editoriais.

Esses dados foram organizados para leitura humana. O desafio é torná-los comparáveis, testáveis e revisáveis de modo sistemático.

ANCHIETA

fonte histórica

SUBSTITUIR POR PNG/JPB

ANCHIETA, 1595

[REFERÊNCIA /
PÁGINA A INSERIR]

CORPUS

Araújo ou Bettendorff

SUBSTITUIR POR PNG/JPB

**ARAÚJO OU
BETTENDORFF**

[FONTE / PÁGINA A
INSERIR]

MODERNA

descrição / dicionário

SUBSTITUIR POR PNG/JPB

**DESCRIÇÃO OU
DICIONÁRIO
MODERNO**

[REFERÊNCIA A
INSERIR]

UMA LINHA CONCRETA

Uma linha do corpus pode testar uma gramática

1. FORMA ATESTADA

LINHA ATESTADA

A mesma linha deve alimentar todos os painéis

[FONTE / PÁGINA A INSERIR]

2. ANÁLISE LINGUÍSTICA
[INSERIR AQUI
O FENÔMENO
ESCOLHIDO, A
SEGMENTAÇÃO
E A LEITURA
GRAMATICAL
DA MESMA
LINHA]

3. EXPRESSÃO FORMAL

T000: expressao formal

```
clause{  
  subject=...  
  predicate=...  
  features={...}  
}
```

PYDICATE / REPRESENTAÇÃO
FORMAL

4. SAÍDA GERADA

SAIDA GERADA

Forma/anotacao da mesma linha

forma-superficial
morfema morfema morfema
GLOSSA GLOSSA GLOSSA

FORMA E ANOTAÇÃO GERADAS

A forma atestada confronta a
análise formal.

REGRA?

ANÁLISE?

LÉXICO?

VARIAÇÃO ORTOGRÁFICA?

TRADIÇÃO TEXTUAL?

CÓDIGO COMO METALINGUAGEM LINGÜÍSTICA

Linguistas já usam metalinguagens formais.

PROSA

regra formulada
em linguagem
natural

GLOSA

segmentação e
valores
gramaticais

REPRESENTAÇÃO FORMAL

análise escrita
como estrutura
explícita

SAÍDA VERIFICÁVEL

forma
comparável ao
corpus

Uma linguagem de programação também pode funcionar como metalinguagem formal para descrição linguística.

METALINGUAGENS EM COMPARAÇÃO

Da prosa gramatical à formalização executável

ANCHIETA: MESMO FENOMENO

Capturar passagem específica da gramática

ANCHIETA, 1595
[PASSAGEM / PÁGINA A INSERIR]

DESCRICAO MODERNA

Mesmo fenomeno da passagem de Anchieta

DESCRIÇÃO MODERNA
[AUTOR, OBRA, PÁGINA A INSERIR]


TODO: expressao formal

```
clause(  
  subject=...  
  predicate=...  
  features={...}  
)
```

GRAMÁTICA EXECUTÁVEL
MESMO FENÔMENO, CAMADA FORMAL

A necessidade de uma metalinguagem permanece; as metalinguagens disponíveis mudam.

Cada linha validada vira um teste.




Quando uma regra muda, as análises anteriores são regeneradas e testadas novamente.

O QUE EXISTE E O QUE MUDA AGORA

As aplicações são saídas. O objeto científico é a gramática.

Já implementado

flexão e conjugação, geração de dicionários, exercícios, variantes ortográficas e ferramentas ligadas à anotação.



Agora, no doutorado

aplicar e aperfeiçoar essa gramática contra o corpus conhecido do Tupi Antigo, linha por linha.

1. corpus histórico
2. formalização linha por linha
3. gramática revisada
4. análises anteriores ainda testáveis
5. corpus cada vez mais estruturado

RESULTADO ATUAL

[INSERIR UM RESULTADO EMPÍRICO CONCRETO]

POR QUE IMPORTA

O corpus obriga a gramática a prestar contas.

Uma gramática publicada

registra uma análise e fixa uma versão argumentada da descrição.

Uma gramática executável e versionada

- mostra que regra mudou;
- indica quais exemplos motivaram a mudança;
- revela o que continua funcionando;
- expõe quais análises quebram;
- testa se a mudança melhora a cobertura do corpus.

Isso acrescenta explicitude, reprodutibilidade e testabilidade à descrição linguística.

Não é transformar o Tupi Antigo em um problema de PLN.

É tornar a descrição linguística mais explícita, verificável, revisável e reutilizável.

A gramática deixa de ser apenas uma interpretação do corpus e passa a ser uma hipótese que o corpus pode testar.